

Ahora si los valores están en la frontera:

$Pr(\text{decisión}) = \{x \in \mathbb{R}^n \mid f_1(x) \pi_1 = f_2(x) \pi_2\}$ Si esto pasa, se echa un volado para ver si va a π_1 ó π_2

LDA (caso homogéneo) ($\Sigma_1 = \Sigma_2$)

$$f_1(x) \sim N_n(\mu_1, \Sigma_1) \quad \wedge \quad f_2(x) \sim N_n(\mu_2, \Sigma_2)$$

Tarea: 27 de marzo

Expo: Ori \rightarrow 23 marzo


Naïve Bayes y su implementación en Python

jueves 14 marzo

Análisis lineal por discriminantes (LDA)

Método de reducción en dimensión y es un clasificador de variables

Habíamos definido las probabilidades:



(i) $C = \bigcup_{i=1}^n \pi_i$ π_i es un conjunto
ajena (el i-ésimo grupo)

$$\pi_i \cap \pi_j = \emptyset \quad \forall i \neq j$$

es decir, $\{\pi_i\}_{i=1}^n$ forma una partición de C

(ii) Sea $X = (x_1, \dots, x_n)$ un vector aleatorio

$$\{\pi_i = P(X \in \pi_i)\}_{i=1}^n$$

Probabilidades a posteriori

$$P(X=x \mid X \in \pi_i) = f_i(x)$$

A priori (Regla de Bayes)

$$P(\pi_i \mid x) = P(X \in \pi_i = X=x)$$

$$P(B|A) = \frac{P(A|B)P(B)}{\sum_{i=1}^n P(A|B_i)P(B_i)}$$

como tener ...

$$\text{Por Bayes (Prueba I)} \\ P(\pi_i \mid x) = \frac{f_i(x) \pi_i}{\sum_{l=1}^n f_l(x) \pi_l}$$

Regla de decisión: para $i \neq j$

$$\frac{P(\pi_i \mid x)}{P(\pi_j \mid x)} = \frac{f_i(x) \pi_i}{f_j(x) \pi_j} > 1 \quad x \rightsquigarrow \pi_i \quad \bullet \text{ tienen el mismo denominador}$$

en otro caso $x \rightsquigarrow \pi_j$


estadístico "odd"

Si estamos $R = \{x \in \mathbb{R}^n \mid f_i(x) \pi_i = f_j(x) \pi_j\}$, hacemos un volado para decidir ejemplo:

LDA (Fisher)

Hipótesis: $f_i(\cdot)$ es la densidad de una v.a. $N(\mu_i, \Sigma_i)$

Caso $i=1,2$ π_1, π_2



$$f_i(x) = \frac{1}{\sqrt{(2\pi)^n |\det \Sigma_i|}} \exp \left\{ -\frac{1}{2} (x - \mu_i)^t \Sigma_i^{-1} (x - \mu_i) \right\}$$

Hipótesis: Caso homogénea $\Sigma_1 = \Sigma_2$

$$\frac{P(\pi_1|x)}{P(\pi_2|x)} = \frac{e^{-\frac{1}{2} (x - \mu_1)^t \Sigma^{-1} (x - \mu_1)} \pi_1}{e^{-\frac{1}{2} (x - \mu_2)^t \Sigma^{-1} (x - \mu_2)} \pi_2}$$

log inyectiva

$$\log \left(\frac{P(\pi_1|x)}{P(\pi_2|x)} \right) = -\frac{1}{2} (x - \mu_1)^t \Sigma^{-1} (x - \mu_1) + \frac{1}{2} (x - \mu_2)^t \Sigma^{-1} (x - \mu_2) + \log \left(\frac{\pi_1}{\pi_2} \right)$$

"=" $b_0 + b x$, b y x son vectores

$$(i) = (\underbrace{\mu_1 - \mu_2}_{\text{vector de medias}})^t \Sigma^{-1} x - \frac{1}{2} \Sigma^{-1} (\mu_1 + \mu_2) (\mu_1 - \mu_2)^t$$

$$x_1 = (x_{11}, \dots, x_{1n})$$

$$\mu_1 = (\mathbb{E}(x_{11}), \dots, \mathbb{E}(x_{1n}))$$

$$(i) = b_0 + b x \quad \text{donde: } b_0 = -\frac{1}{2} (\mu_1^t \Sigma^{-1} \mu_1 - \mu_2^t \Sigma^{-1} \mu_2) + \log \left(\frac{\pi_1}{\pi_2} \right)$$

$$b = \Sigma^{-1} (\mu_1 - \mu_2)$$

$$\log \left(\frac{P(\pi_1|x)}{P(\pi_2|x)} \right) = b_0 + b^t x \quad \dots \text{LDA lineal}$$

¿Que programar LDA?


Esquema:



Matriz de dispersión

S_W, S_B se tienen que mostrar las proyecciones

2 grupos



$$X = (x_1, \dots, x_n)$$

Suponer $n_1 \neq \pi_1$
 $n_2 \neq \pi_2$

$$n = n_1 + n_2$$

Recordemos que una proyección de una variable x a una variable y : es un valor w tal que

$$y = w^t x$$

$$w = (w_1, \dots, w_n)$$

$$x = (x_1, \dots, x_n)$$

$$\pi_1 = \{x_1, \dots, x_{n_1}\}$$

$$\pi_2 = \{x_1^2, \dots, x_{n_2}^2\}$$

> Calcular la media de cada uno de los puntos

Calcular la media

$$i=1,2 \quad \mu_i = \frac{1}{n_i} \sum_{x \in \pi_i} x$$

$$\tilde{\mu}_i = \frac{1}{n_i} \sum_{y \in \pi_i} y$$

NOTA:

$$\tilde{\mu}_i = \frac{1}{n_i} \sum_{y \in \pi_i} w^t x = \frac{1}{n_i} w^t \sum_{x \in \pi_i} x = w^t \frac{1}{n_i} \sum_{x \in \pi_i} x = w^t \mu_i$$

$$\therefore \tilde{\mu}_i = w^t \mu_i$$

Se puede tener: la distancia ... ?

$$J(w) = |\tilde{\mu}_1 - \tilde{\mu}_2| = |w^t \mu_1 - w^t \mu_2| = |w^t (\mu_1 - \mu_2)|$$

↓

distancia entre

los medias proyectadas

Definición: (Scatter)

Con las notaciones anteriores

$$\tilde{S}_i^2 = \sum_{y \in \pi_i} (y - \tilde{\mu}_i)^2 \quad \left. \vphantom{\sum_{y \in \pi_i}} \right\} \text{Variabilidad de los datos después de ser proyectados}$$

(NOTA Varianza para los valores proyectados)

Vamos a definir la i -ésima matriz scatter como:

$$S_i = \sum_{x \in \pi_i} (x - \mu_i)^t (x - \mu_i) \quad i=1,2$$

$$S_W = S_1 + S_2 \quad \text{matriz scatter within}$$

y la distancia entre las medias proyectadas normalizadas por la variabilidad de las medias proyectadas

$$J(w) = \frac{|w^t(\mu_1 - \mu_2)|}{\tilde{S}_1^2 + \tilde{S}_2^2 \dots \text{suma de varianzas}}$$

De aquí;

$$\tilde{S}_1^2 = \sum_{x \in \pi_i} (w^t x - w^t \mu_i)^2$$

$$= \sum_{x \in \pi_i} (w^t(x - \mu_i))^2 = \sum_{x \in \pi_i} w^t \underbrace{(x - \mu_i)(x - \mu_i)^t}_{S_i} w = w^t S_i w$$

$$\therefore \tilde{S}_i^2 = w^t S_i w$$

La matriz scatter es:

$$S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^t \dots \text{llamada: matriz scatter between}$$

Así:

$$J(w) = \frac{|\tilde{\mu}_1 - \tilde{\mu}_2|}{\tilde{S}_1^2 + \tilde{S}_2^2} = \frac{|w^t(\mu_1 - \mu_2)|}{w^t S_w w}$$

elevando al cuadrado

$$|\tilde{\mu}_1 - \tilde{\mu}_2|^2 = w^t(\mu_1 - \mu_2)(\mu_1 - \mu_2)^t w$$

Finalmente,

$$J(w) = \underbrace{\frac{w^t S_B w}{w^t S_w w}}_{\text{parte empírica}} \longleftrightarrow \underbrace{\log \left(\frac{P(\pi_1 | x)}{P(\pi_2 | x)} \right)}_{\text{parte teórica}}$$

¿Cómo obtener a w ?

$$\frac{dJ(w)}{dw} = 0 \quad \text{equivalentemente} \quad 0 = (w^t S_w w) \frac{dw^t S_B w}{dw} - (w^t S_B w) \frac{dw^t S_w w}{dw}$$

$$0 = (w^t S_w w) 2 S_B w - (w^t S_B w) 2 S_w w$$

$$0 = S_B w - J(w) \cdot S_w w \implies J(w) S_w w = S_B w$$

multiplicando por S_w^{-1}

$$\longrightarrow J(w) w = S_w^{-1} S_B w \quad \text{es una medida (es un número)}$$

Teorema (Fisher)

(con las notaciones anteriores)

$$(S_w^{-1} S_B) w = J(w) \cdot w \quad \text{satisface a los eigenvalores}$$

$J(w)$ es eigenvalor de $S_w^{-1} S_B$ ■

De hecho,

$S_x = S_w^{-1} S_B \dots$ llamada la matriz de covarianzas